

Detección de Fraude en Transacciones Bancarias mediante Técnicas de Agrupamiento y Detección de Anomalías

- Cortes Moreno Mauricio Hamabiel, Pacheco Molina Miguel Alejandro, Maldonado López Alejandro, Soria Martínez Jesús Armando

Resumen – La detección de fraude bancario enfrenta el reto del alto desbalance entre transacciones legítimas y fraudulentas. Este trabajo propone un enfoque híbrido que integra aprendizaje supervisado y no supervisado para mejorar la identificación de fraudes en datos de tarjetas de crédito altamente desbalanceados. Se utilizó un modelo Random Forest como línea base, aplicando SMOTE para mitigar el desbalance de clases. Posteriormente, se empleó K-Means para identificar patrones de comportamiento, determinando el número óptimo de clústeres mediante el coeficiente de silueta. Adicionalmente se entrenó un mapa autoorganizado (SOM), y sobre los pesos obtenidos de sus neuronas se aplicó K-Means. La información derivada de los clústeres fue incorporada mediante ingeniería de características, incluyendo pertenencia y distancias a clústeres. Con este nuevo conjunto de datos se entrenó un modelo híbrido de Random Forest, obteniendo mejoras en las métricas de evaluación, especialmente en recall y F1-score, lo que evidencia que la combinación de técnicas supervisadas y no supervisadas permite capturar patrones más complejos y mejorar la detección de fraude bancario.

Palabras Clave – Fraude bancario, aprendizaje no supervisado, K-means, Self-Organizing Map (SOM), Random Forest, detección de anomalías, SMOTE.

1. Introducción

El fraude en transacciones bancarias representa uno de los principales desafíos para las instituciones financieras en la era digital. El crecimiento exponencial de los pagos electrónicos, el comercio en línea y las plataformas financieras incrementó tanto el volumen de transacciones como la complejidad de los patrones de fraude, generando pérdidas económicas significativas y afectando la confianza de los usuarios. Por lo que, los métodos tradicionales basados en reglas fijas resultan insuficientes, ya que carecen de la flexibilidad necesaria para adaptarse a nuevas estrategias utilizadas por los defraudadores.

La aplicación de técnicas de ciencia de datos y aprendizaje automático se ha convertido en una herramienta fundamental para la detección de fraude. Estos enfoques permiten analizar grandes volúmenes de datos, identificar patrones complejos de comportamiento y detectar anomalías que pueden pasar desapercibidas mediante métodos convencionales. Sin embargo, el fraude bancario presenta características particulares que dificultan su detección, como el alto desbalance entre clases, la dinámica cambiante del comportamiento fraudulento y la limitada disponibilidad de etiquetas confiables.

En el presente proyecto se propone un enfoque híbrido para la detección de fraude en transacciones bancarias, combinando técnicas de aprendizaje no supervisado y aprendizaje supervisado. En particular, se emplean métodos de agrupamiento y análisis de anomalías, como K-Medias y Mapas Autoorganizados (Self-Organizing Maps, SOM), junto con un modelo de clasificación supervisada basado en Random Forest. El uso de SOM y del concepto de Unidad de mejor Coincidencia (Best Matching Unit, BMU) permite proyectar datos de alta dimensionalidad en un espacio reducido, facilitando la identificación de patrones de comportamiento y transacciones atípicas que pueden estar asociadas a actividades fraudulentas.

El estudio se basa en el conjunto de datos Credit Card Fraud Detection de la plataforma Kaggle contiene transacciones reales anonimizadas mediante técnicas de reducción de dimensionalidad. Dicho conjunto de datos presenta un severo desbalance entre transacciones legítimas y fraudulentas, lo que lo convierte en un escenario adecuado para evaluar técnicas avanzadas de detección de anomalías y clasificación.

2. Objetivo

Desarrollar un sistema de detección de fraude en transacciones bancarias mediante la aplicación de técnicas de agrupamiento, detección de anomalías y clasificación supervisada, siguiendo la metodología CRISP-DM, con el fin de identificar transacciones fraudulentas de manera eficiente y confiable.

2.1 Objetivos específicos:

- Analizar y preparar los datos de transacciones bancarias para la detección de fraude.
- Aplicar técnicas de aprendizaje no supervisado y supervisado para identificar patrones y anomalías.
- Evaluar el desempeño del enfoque híbrido en la detección de transacciones fraudulentas.

3. Estado del arte

La detección de fraude bancario ha sido constantemente estudiada debido a las importantes pérdidas económicas que genera y a la complejidad de los patrones fraudulentos. Los enfoques tradicionales basados en reglas han demostrado ser poco flexibles frente a nuevos tipos de fraude que evolucionan constantemente, lo que ha impulsado la adopción de técnicas de aprendizaje automático para abordar este problema.

En el ámbito del aprendizaje supervisado, algoritmos como la regresión logística, las máquinas de soporte vectorial y Random Forest han mostrado un buen desempeño en la clasificación de transacciones fraudulentas. En particular, Random Forest destaca por su capacidad para manejar grandes volúmenes de datos, relaciones no lineales y múltiples variables, lo que lo convierte en una de las técnicas más utilizadas en este contexto. Breiman [1] demostró que este modelo reduce el sobreajuste mediante la combinación de múltiples árboles de decisión, haciéndolo robusto para problemas complejos como la detección de fraude. Sin embargo, estos modelos presentan dificultades cuando se enfrentan a conjuntos de datos altamente desbalanceados, donde la clase fraudulenta representa una proporción mínima de las observaciones [2].

Para mitigar este problema, Chawla et al. [3] propusieron la técnica SMOTE (Synthetic Minority Over-sampling Technique), la cual genera ejemplos sintéticos de la clase minoritaria. Los autores demostraron que esta estrategia mejora la capacidad de los clasificadores para identificar eventos raros, incrementando métricas como el recall en conjuntos de datos con fuerte desbalance de clases.

Por otro lado, los enfoques de aprendizaje no supervisado han sido utilizados para identificar patrones atípicos en las transacciones, bajo la premisa de que el fraude se comporta como una anomalía. Algoritmos de agrupamiento como K-Means permiten explorar la estructura interna de los datos y detectar comportamientos inusuales, aunque no cuentan con capacidad predictiva directa debido a que no utilizan etiquetas de clase [4].

En investigaciones más recientes se han propuesto enfoques híbridos que combinan aprendizaje supervisado y no supervisado, integrando información derivada del agrupamiento como nuevas características para los modelos de clasificación. Estos enfoques han demostrado mejorar el desempeño en la detección de fraude al incorporar información sobre la estructura interna de los datos [5]. De esta manera, el presente trabajo se alinea con estas propuestas al combinar Random Forest y K-Means para fortalecer la detección de transacciones fraudulentas.

4. Metodología

Con el objetivo de desarrollar de una manera eficaz el presente proyecto se optó la metodología CRISP-DM (Cross – Industry Standard Process For Data Mining), la cual es un estándar ampliamente utilizado para proyectos de ciencia de datos debido a su enfoque estructurado, iterativo y orientado a la resolución de

problemas reales del negocio. La metodología consta de seis fases: comprensión del negocio, comprensión de los datos, preparación de los datos, modelado, evaluación y despliegue.



Figura 1. CRISP-DM.

4.1 Entendimiento del negocio

En el contexto bancario, el fraude en transacciones representa una problemática crítica debido a las pérdidas económicas directas, teniendo como impacto la confianza que tienen los clientes y los costos asociados a investigación y gestión de alertas. Con el fin de abordar esta problemática el objetivo es identificar transacciones fraudulentas de manera temprana y precisa, utilizando técnicas de aprendizaje automático que permitan detectar tanto patrones conocidos de fraude como comportamientos anómalos. Desde el punto de vista del negocio, en definitiva, se busca reducir las pérdidas económicas asociadas al fraude, minimizar la cantidad de falsos positivos que pueden llegar a generar sobrecarga operativa y, por último, contar con un modelo interpretable y escalable.

El criterio de éxito del proyecto se define a través de métricas de desempeño del modelo, tales como precisión (precision), recall, F1-Score y AUC (área bajo la curva), teniendo énfasis en la capacidad del sistema para detectar la mayor cantidad posible de transacciones fraudulentas sin incrementar los falsos positivos.

4.2 Entendimiento de los datos

La fase de comprensión de los datos fue realizada mediante un análisis detallado del conjunto de datos utilizado con el objetivo de comprender su estructura, contenido, calidad y relación con el problema de detección de fraude. El conjunto de datos seleccionado fue “**Credit Card Fraud Detection**”, disponible en la plataforma Kaggle, el cual es ampliamente utilizado como referencia en estudios académicos y aplicaciones prácticas relacionadas con fraude financiero.

El conjunto de datos contiene 284,807 transacciones realizadas con tarjetas de crédito, de las cuales 492 corresponden a transacciones fraudulentas, lo que representa aproximadamente el 0.172% del total. Esta característica refleja fielmente la naturaleza real del fraude bancario, donde los eventos fraudulentos son escasos en comparación con las transacciones legítimas. Para cada registro se representa una transacción individual y está compuesto por 29 variables numéricas (V1 a V28), las cuales corresponden a componentes principales obtenidas mediante el procedimiento de Análisis de Componentes Principales (PCA); el procedimiento fue aplicado para proteger la confidencialidad de la información de los clientes.

La variable Tiempo, indica el tiempo transcurrido en segundos desde la primera transacción registrada en el conjunto de datos, mientras que la variable Monto representa el monto de la transacción y, por último, la variable

Clase, actúa como la etiqueta objetivo donde el valor de 0 indica una transacción legítima, mientras que el valor de 1 indica una transacción fraudulenta. Cabe mencionar que, la presencia de variables transformadas mediante PCA implica que no es posible interpretar directamente su significado desde el punto de vista del negocio; sin embargo, estas variables conservan la información necesaria para identificar patrones relevantes asociados al fraude.

Data columns (total 31 columns):				
#	Column	Non-Null Count		Dtype
0	Tiempo	284807 non-null		float64
1	V1	284807 non-null		float64
2	V2	284807 non-null		float64
3	V3	284807 non-null		float64
4	V4	284807 non-null		float64
5	V5	284807 non-null		float64
6	V6	284807 non-null		float64
7	V7	284807 non-null		float64
8	V8	284807 non-null		float64
9	V9	284807 non-null		float64
10	V10	284807 non-null		float64
11	V11	284807 non-null		float64
12	V12	284807 non-null		float64
13	V13	284807 non-null		float64
14	V14	284807 non-null		float64
15	V15	284807 non-null		float64
16	V16	284807 non-null		float64
17	V17	284807 non-null		float64
18	V18	284807 non-null		float64
19	V19	284807 non-null		float64
20	V20	284807 non-null		float64
21	V21	284807 non-null		float64
22	V22	284807 non-null		float64
23	V23	284807 non-null		float64
24	V24	284807 non-null		float64
25	V25	284807 non-null		float64
26	V26	284807 non-null		float64
27	V27	284807 non-null		float64
28	V28	284807 non-null		float64
29	Monto	284807 non-null		float64
30	Clase	284807 non-null		int64

Figura 2. Conjunto de Datos.

Uno de los aspectos más relevantes identificados durante la exploración inicial es el fuerte desbalance de clases. En la Figura 3, se muestra una proporción extremadamente baja de transacciones fraudulentas que representa un desafío significativo para los algoritmos de aprendizaje automático, ya que modelos entrenados sin una estrategia adecuada tienden a favorecer la clase mayoritaria, obteniendo una alta exactitud global pero un bajo desempeño en la detección de fraude.




Figura 3. Desbalance de clases.

En la Figura 4, se muestra la variable **Monto** que contiene una distribución altamente asimétrica, con una gran concentración de transacciones de bajo monto y pocos valores extremadamente altos.




Figura 4. Distribución de la variable Monto.

Mientras que, en la Figura 5, se muestra la variable Tiempo permite identificar patrones temporales en el comportamiento de las transacciones, aunque no representa una escala temporal absoluta (como fecha u hora del día).




Figura 5. Distribución de la variable Tiempo.

El conjunto de datos no contiene valores faltantes, lo cual simplifica el proceso de preparación y reduce el riesgo de sesgos introducidos por imputaciones, no presenta registros duplicados y cuenta con variables numéricas consistentes y aptas para ser utilizadas por algoritmos tanto supervisados como no supervisados. En definitiva, el análisis realizado en esta fase permitió comprender las limitaciones y fortalezas del conjunto de datos, sentando las bases para una adecuada preparación de los datos y el desarrollo de modelos robustos de detección de fraude en las fases posteriores del proceso CRISP-DM.

4.3 Preparación de los datos

En esta etapa se realizaron diversas transformaciones y procesos con el objetivo de obtener un conjunto de datos, limpio, balanceado y adecuado para la fase del modelo. Como primer paso del preprocesamiento, se procedió a la asignación de la variable objetivo **Clase**, la cual indica si una transacción es fraudulenta (1) o legítima (0). Esta variable fue separada del conjunto de variables predictoras para su uso exclusivo como etiqueta durante el entrenamiento de los modelos supervisados. Las variables independientes incluyeron las componentes principales V1–V28, así como las variables **Tiempo** y **Monto**, las cuales contienen información relevante sobre el comportamiento temporal y económico de las transacciones.

Con el fin de evaluar de una manera eficaz el desempeño de los modelos, se optó por una partición del conjunto de entrenamiento (80%), utilizado para el aprendizaje de los modelos y un conjunto de prueba (20%), reservado

exclusivamente para la evaluación final del desempeño. Dado que los algoritmos utilizados, particularmente K-Means, son sensibles a la escala de las variables, se aplicó un proceso de estandarización mediante el método *StandardScaler*. Este procedimiento transforma las variables para que tengan media cero y desviación estándar uno. Aunque las variables V1–V28 ya se encuentran parcialmente escaladas debido al uso previo de PCA, el escalado adicional resulta especialmente relevante para variables como Monto y Tiempo, garantizando que todas las características contribuyan de manera equilibrada al cálculo de distancias y a la construcción de los modelos.

Uno de los principales retos del problema de detección de fraude es el severo desbalance entre transacciones legítimas y fraudulentas. Para abordar esta problemática, se empleó la técnica Técnica de Sobremuestreo de la Clase Minoritaria SMOTE sobre el conjunto de entrenamiento. Es importante destacar que SMOTE se aplicó exclusivamente sobre el conjunto de entrenamiento, preservando el desbalance natural en el conjunto de prueba. De esta forma, la evaluación del modelo se realiza en condiciones realistas, similares a las que se presentan en un entorno operativo.

4.4 Modelado

En esta fase de modelado se decidió adoptar un enfoque híbrido que combina técnicas de aprendizaje supervisado y no supervisado, con el objetivo de mejorar la detección de transacciones fraudulentas en un contexto de datos altamente desbalanceados. Este enfoque nos permite aprovechar la capacidad predictiva de los modelos supervisados como la identificación de patrones internos en los datos mediante técnicas de agrupamiento.

Como modelo supervisado se utilizó *Random Forest*, un algoritmo de clasificación basado en un conjunto de árboles de decisión entrenados sobre subconjuntos aleatorios de los datos y de las variables, la predicción final se obtienen mediante un proceso de votación entre los árboles lo que permite reducir el sobreajuste y mejorar la capacidad de generalización del modelo, *Random Forest* es adecuado para problemas de fraude bancario debido a su robustez frente al ruido, su capacidad para modelar relaciones no lineales y su buen desempeño en escenarios con múltiples variables numéricas.

Para establecer un punto de referencia, se entrenó inicialmente el modelo de *Random Forest* utilizando solo las variables originales del conjunto de datos, debido que el conjunto presentaba un desbalance fuerte entre transacciones legítimas y fraudulentas, se decidió aplicar la técnica *SMOTE (Synthetic Minority Over-sampling Technique)* únicamente al conjunto de entrenamiento para así lograr un equilibrio entre las clases, esta técnica permite generar observaciones sintéticas de la clase minoritaria, favoreciendo un aprendizaje más equilibrado del modelo.

Posteriormente se utilizó el algoritmo *K-means* como técnica de aprendizaje no supervisado con el objetivo de identificar patrones de comportamiento similares entre las transacciones. *K-means* agrupa las observaciones en un número predefinido de clústeres minimizando la distancia entre los puntos y sus centroides, esto permite capturar estructuras internas en los datos. Antes del agrupamiento las variables fueron escaladas para evitar que aquellas con mayor magnitud influyeran de manera desproporcionada en los cálculos de distancia.

La selección del número óptimo de clústeres se realizó primero mediante el análisis del *Método del Codo* considerando un rango de valores de K entre 1 y 10, sin embargo, al no identificarse un codo pronunciado claramente definido en la curva de la inercia, se decidió utilizar el *Método de Silueta* como método complementario, este permite evaluar la cohesión interna y la separación entre los clústeres formados seleccionando el valor de k que maximiza la métrica.

A partir del modelo de K-Means entrenado con el número óptimo de clústeres, se realizó un análisis exploratorio de los grupos obtenidos con el fin de identificar diferencias en el comportamiento de las transacciones, para poder facilitar la interpretación visual de los clústeres utilizamos una proyección de los datos mediante *Análisis*

de *Componente Principales (PCA)*, esto nos permitió observar la distribución relativa de las transacciones en el espacio reducido.

Se analizó la relación entre los clústeres formados y la variable objetivo observando la proporción de transacciones fraudulentas presente en cada grupo, con esto identificamos clústeres con mayor presencia de fraude lo que nos indica que ciertos patrones de comportamiento están más asociados a actividades fraudulentas.

A partir de estos resultados realizamos un proceso de ingeniería de características con el fin de enriquecer el conjunto de datos original, primero añadimos una nueva característica que indica el clúster al que pertenece cada transacción, esto proporciona al modelo información sobre el tipo de comportamiento al que está asociada.

También se calculó la distancia de cada transacción a su centroide correspondiente, esta medida ayuda a identificar qué tan representativa es una transacción dentro de su clúster, distancias pequeñas suelen indicar comportamientos normales mientras que distancias grandes sugieren transacciones atípicas que podrían estar relacionadas con fraude.

Finalmente se incorporó una medida de confianza de que una transacción pertenezca al clúster definida como la diferencia entre la distancia al centroide más cercano y la distancia al segundo centroide más cercano.

- Valor bajo = Transacción en zona ambigua entre clústeres = Sospechoso.
- Valor alto = Comportamiento claro.

Estas nuevas características fueron agregadas al conjunto de datos original y de esta manera se construyó un segundo modelo de Random Forest que aprovecha la información adicional sobre la estructura interna de los datos.

Posteriormente, para entrenar el tercer modelo de Random Forest, se implementó un Mapa Autoorganizado (Self-Organizing Map, SOM) utilizando los datos previamente escalados. El SOM es un modelo de aprendizaje no supervisado que proyecta datos de alta dimensionalidad en una malla bidimensional de neuronas, preservando en la medida de lo posible la estructura topológica de los datos originales.

Una vez entrenado el SOM, se visualizó su comportamiento mediante el mapa de distancias, el cual representa la distancia entre los pesos de neuronas vecinas en la cuadrícula. En esta representación, los tonos más claros indican neuronas con pesos similares, lo que sugiere regiones homogéneas o agrupaciones, mientras que los tonos más oscuros representan mayores distancias entre neuronas, interpretándose como posibles fronteras entre grupos.

Posteriormente, se identificaron las Best Matching Units (BMU), o Unidades de Emparejamiento, correspondientes a cada transacción, es decir, las neuronas cuyo vector de pesos resulta más cercano a cada observación. Con base en estas neuronas ganadoras, los datos fueron proyectados mediante Análisis de Componentes Principales (PCA), donde cada punto fue coloreado según su BMU asociada, con el objetivo de evaluar visualmente la separación y coherencia de los grupos generados por el SOM.

A continuación, se aplicó el algoritmo K-means sobre los vectores de pesos de las neuronas ganadoras del SOM, con el objetivo de agrupar las neuronas en clústeres globales y capturar patrones de comportamiento similares. Este procedimiento permite combinar la estructura topológica aprendida por el SOM con un método de agrupamiento clásico.

A partir de los clústeres obtenidos, se siguió el mismo procedimiento aplicado en el modelo previo basado en K-means. Se analizó la relación entre los clústeres y la variable objetivo para identificar grupos con mayor presencia de fraude y, posteriormente, se realizó un proceso de ingeniería de características incorporando el identificador del clúster, la distancia mínima al centroide y una medida de confianza de pertenencia.

Finalmente, estas nuevas características fueron integradas con las variables originales para construir un conjunto de datos híbrido, sobre el cual se aplicó SMOTE al conjunto de entrenamiento y se entrenó el tercer modelo de Random Forest.

4.5 Evaluación

Para el primer modelo de Random Forest entrenado sobre los datos originales con SMOTE, se obtuvo un f1-score macro de 0.92, lo que es un buen rendimiento considerando el desbalance de las clases. Por otro lado, esta fue la matriz de confusión obtenida de ese modelo:





Figura 6: Matriz de confusión del modelo Random Forest base.

- **56852: Verdaderos Negativos (VN):** Instancias de clase 0 que fueron correctamente clasificadas como clase 0.
- **12: Falsos Negativos (FN):** Instancias de clase 0 que fueron incorrectamente clasificadas como clase 1.
- **19: Falsos Positivos (FP):** Instancias de clase 1 que fueron incorrectamente clasificadas como clase 0.
- **79: Verdaderos Positivos (VP):** Instancias de clase 1 que fueron correctamente clasificadas como clase 1.

De acuerdo con los resultados de la matriz de confusión se puede observar que el modelo aprendió correctamente la clase mayoritaria (no fraude), ya que solo se equivocó en 12 transacciones, pero, por el contrario, en cuanto a la clase minoritaria (fraude), se puede observar que le cuesta clasificarla correctamente, a pesar de que, solo clasifiqué mal 19 transacciones, esto representa una quinta parte de esa clase, por lo que se intentará reducir ese número con los otros modelos que usan agrupamiento.



En cuanto la curva ROC, el AUC fue de 0.97, lo que indica que un desempeño excelente, casi ideal, del modelo para discriminar entre las dos clases (fraude vs no fraude).

Figura 7: Curva ROC del modelo Random Forest base.

Después de identificar el número de grupos más óptimo, se entrenó K-means con $k=4$. En la siguiente imagen se observa la distribución de los grupos con PCA:




Figura 8: Grupos creados con K-means.

En el grafico de PCA se pueden observar 3 grupos principales, estos de color verde, rojo y naranja, estos están juntos, pero son fácilmente identificables por su color, ya que no están muy revueltos, solo hay algunos puntos azules de un cuarto grupo que se encuentra disperso entre los demás.

Porcentaje de fraude por grupo:

Grupo	Porcentaje
0	0.001271
1	0.030837
2	0.001103
3	0.001287

Tabla 1: Porcentaje de fraude por cluster con K-means.

El segundo modelo, ya es un híbrido entre Random Forest y agrupamiento con k-means, este alcanzo un f1-score macro de 0.92 y un recall de 0.92, superando con este último al modelo anterior, y su matriz de confusión es la siguiente:




Figura 9: Matriz de confusión del modelo Random Forest + K-means.

- **56847: Verdaderos Negativos (VN):** Instancias de clase 0 que fueron correctamente clasificadas como clase 0.
- **17: Falsos Negativos (FN):** Instancias de clase 0 que fueron incorrectamente clasificadas como clase 1.
- **15: Falsos Positivos (FP):** Instancias de clase 1 que fueron incorrectamente clasificadas como clase 0.
- **83: Verdaderos Positivos (VP):** Instancias de clase 1 que fueron correctamente clasificadas como clase 1.

De acuerdo con los resultados de la matriz de confusión se logró reducir 4 de los Falsos Positivos y la curva ROC se mantuvo igual, con un AUC de 0.97.

El tercer modelo de Random Forest entrenado, es un híbrido entre SOM y K-means.

La figura 10 sirve para poder visualizar el resultado del SOM, lo que se hace es utilizar un mapa de distancias, este mapa muestra las neuronas del SOM como una cuadrícula de celdas, donde el color de cada célula representa su distancia a las neuronas vecinas.




Figura 10: Mapa de distancia del conjunto de datos de entrenamiento.

Los tonos más claros representan las neuronas que están muy próximas entre sí, lo que puede interpretarse como agrupaciones, por otro lado, los tonos más oscuros, son las neuronas más alejadas, lo que se puede interpretar como límites entre grupos.

Después de haber entrenado el SOM, se graficaron los datos con PCA, los colores cambian según la neurona ganadora que se esté representando, se puede observar como los grupos están demasiado encimados y son difíciles de distinguir.




Figura 11: Grupos detectados por SOM.

Este modelo alcanzo un f1-score macro de 0.92, y un recall de 0.91, por lo que igual logra superar al primer modelo, y su matriz de confusión quedo así:




Figura 12: Matriz de confusión del modelo Random Forest + SOM + K-means.

- **56851: Verdaderos Negativos (VN):** Instancias de clase 0 que fueron correctamente clasificadas como clase 0.
- **13: Falsos Negativos (FN):** Instancias de clase 0 que fueron incorrectamente clasificadas como clase 1.
- **18: Falsos Positivos (FP):** Instancias de clase 1 que fueron incorrectamente clasificadas como clase 0.
- **80: Verdaderos Positivos (VP):** Instancias de clase 1 que fueron correctamente clasificadas como clase 1.

Este modelo logro reducir levemente los Falsos Positivos a comparación del primer modelo, pero no tanto como el segundo modelo, sin embargo, redujo mejor los Falsos Negativos a comparación del segundo modelo, y la curva ROC dio un AUC de 0.96.

Resumen de resultados de los tres modelos.

Modelo	Macro Avg			Curva ROC
	Precision	Recall	F1-macro	
Random Forest + K-means	0.91	0.92	0.92	0.97
Random Forest + SOM + K-means	0.93	0.91	0.92	0.96
Random Forest	0.93	0.9	0.92	0.97

Tabla 2: Resumen de resultados de los tres modelos.

4.6 Despliegue

Considerando que, se busca el que un fraude no sea pasado por alto, se considera que el mejor modelo para una implementación sería *K-Means* + *Random Forest*, para ello, se implementa una función donde se podrá leer y e ingresar una nueva transacción:

```
def clasificar_transaccion_kmeans(transaccion_nueva, escalador, kmeans, modelo_rf, umbral=0.5):  
    transaccion_escalada = escalador.transform(transaccion_nueva) #se hace el escalado  
    cluster_kmeans = kmeans.predict(transaccion_escalada) #se asigna el cluster  
    distancias = kmeans.transform(transaccion_escalada) #se asigna la distancia entre centroides  
    distancia_minima = distancias.min(axis=1)  
    distancias_ordenadas = np.sort(distancias, axis=1) #la confianza  
    confianza_cluster = distancias_ordenadas[:, 1] - distancias_ordenadas[:, 0]  
    vector_hibrido = np.column_stack((transaccion_nueva, cluster_kmeans, distancia_minima, confianza_cluster)) #  
    probabilidad_fraude = modelo_rf.predict_proba(vector_hibrido)[0, 1] #la prob de rf  
    prediccion = int(probabilidad_fraude >= umbral)  
    return prediccion, probabilidad_fraude
```

Figura 13: Código de la función para una transacción nueva.

Donde:

1. Se hace un escalado a la nueva transacción.
2. Se asigna el clúster con la implementación de *K-Means*.
3. Se calcula la distancia con su centroide.
4. Se calcula la confianza.
5. Se agregan estas 3 características a la transacción.
6. Se hace la predicción.

Para poner un ejemplo se ocupa la siguiente transacción:

Time	V1	V2	V3	V4	V5	V6	V7	V8	V9	V10	V11	V12	V13	V14	V15	V16	V17
-1.23	0.45	2.31	-0.87	0.12	-0.55	1.02	-0.33	0.76	-1.11	0.05	0.91	-0.48	0.62	-0.14	0.88	-0.03	0.27
			V18	V19	V20	V21	V22	V23	V24	V25	V26	V27	V28	Amount			
			-1.05	0.19	-0.22	0.41	-0.09	0.56	0.13	-0.07	0.24	-0.18	0.03	149.62			

Tabla 3: Transacción nueva a clasificar.

La Tabla 3 muestra una transacción nueva representada mediante las 30 variables originales del conjunto de datos, la cual se utiliza como entrada para el sistema de clasificación propuesto.

De donde se obtiene la siguiente predicción:

Predicción: No fraude

Probabilidad de fraude: 0.01

La transacción analizada fue clasificada como no fraudulenta, ya que la probabilidad estimada de fraude fue de 0.01, valor considerablemente inferior al umbral de decisión establecido. Esto indica que, de acuerdo con los patrones aprendidos por el modelo, la transacción presenta un comportamiento consistente con operaciones normales y un riesgo muy bajo de fraude.

6. Conclusiones

Soria Martínez Jesús Armando

El fraude bancario representa un problema de alta relevancia, al que tanto las instituciones financieras como los usuarios están constantemente expuestos. Por ello, resulta fundamental proponer soluciones que permitan mejorar su detección, incluso en escenarios donde existe un fuerte desbalance entre transacciones legítimas y fraudulentas.

En este proyecto se entrenó inicialmente un modelo base de Random Forest utilizando únicamente las variables originales del conjunto de datos, con el fin de establecer una línea de referencia. Posteriormente, se propusieron dos enfoques alternativos basados en técnicas de aprendizaje no supervisado para enriquecer el conjunto de características. El primero consistió en la incorporación de variables derivadas del algoritmo K-means, mientras que el segundo combinó un mapa autoorganizado (SOM) con K-means, integrando posteriormente esta información en un nuevo modelo de Random Forest.

De acuerdo con los resultados obtenidos, ambas propuestas superaron el desempeño del modelo base. El modelo que incorporó características generadas mediante SOM y K-means logró una mejora en la métrica de recall, mientras que la propuesta basada únicamente en K-means no solo superó la línea base en recall, sino que además redujo de manera considerable el número de falsos positivos. Estos resultados indican que los algoritmos de agrupamiento son capaces de capturar información estructural adicional en los datos, la cual resulta valiosa para mejorar la capacidad de clasificación del modelo supervisado, aun en presencia de un marcado desbalance de clases.

Pacheco Molina Miguel Alejandro

En este proyecto demostramos que la integración de técnicas no supervisadas con modelos supervisados constituye una estrategia superior para la detección de fraude bancario en entornos de alto desbalance. El modelo propuesto como línea base (Random Forest con SMOTE) ofreció un rendimiento sólido con un Recall de 0.81, pero la implementación de modelos híbridos nos permitió superar este desempeño. El modelo de KMeans + RF resultó ser el más eficaz para minimizar las pérdidas financieras directas, alcanzando el Recall máximo de 0.85. Por otro lado, el modelo más avanzado de SOM + KMeans + RF resultó con el mejor equilibrio operativo entre detección y fiabilidad (Recall 0.82 y Precisión 0.86), así confirmamos que la incorporación de información geométrica y topológica ya sea mediante centroides globales o mapas autoorganizados nos permitió capturar patrones de fraude complejos que los clasificadores tradicionales por sí solos no logran identificar.

Maldonado López Alejandro

En este proyecto se abordó el problema de la detección de fraude en transacciones bancarias mediante un enfoque híbrido que combina técnicas de aprendizaje supervisado y no supervisado, siguiendo la metodología CRISP-DM. Los resultados muestran que Bosques Aleatorios ofrece un desempeño sólido en la detección de fraude, incluso en un conjunto de datos altamente desbalanceado. La incorporación de técnicas no supervisadas

como K-Medias y SOM mejora la detección de la clase fraudulenta, incrementando el recall y reduciendo falsos negativos. Las métricas globales ($F1\text{-macro} \approx 0.92$ y $AUC\text{-ROC} \approx 0.97$) confirman una alta capacidad discriminativa de los modelos. El enfoque híbrido permite capturar tanto patrones conocidos como comportamientos anómalos, ofreciendo una solución robusta y alineada con el contexto del negocio financiero.

Cortes Moreno Mauricio Hamabiel

En este trabajo se desarrolló una herramienta orientada a la detección de fraude mediante la combinación de técnicas de aprendizaje no supervisado y aprendizaje supervisado, con el objetivo de mejorar la capacidad de identificación de patrones y reducir pérdidas monetarias.

La metodología integra algoritmos de agrupamiento, específicamente K-Medias y Mapas Autoorganizados (SOM), para extraer información y patrones de comportamiento presentes en los datos para posteriormente, como nuevas características, complementar el conjunto de datos y con un modelo de clasificación basado en Bosque Aleatorio permita tener un mejor desempeño. Durante la experimentación, los resultados demostraron que el modelo que combina K-Medias y Bosque Aleatorio obtuvo el mejor desempeño en términos de manejo de errores de clasificación, logrando un balance adecuado entre falsos positivos y falsos negativos. En particular, se observó una mejora relevante en la reducción de falsos negativos, aspecto fundamental en escenarios de fraude, ya que estos representan transacciones fraudulentas que no son detectadas y que pueden generar pérdidas económicas significativas, para incorporación de técnicas de agrupamiento como etapa previa al proceso de clasificación aporta información relevante sobre el comportamiento de las transacciones, lo que permite al modelo identificar con mayor eficacia patrones asociados al fraude. Los resultados obtenidos respaldan el uso de enfoques híbridos como una alternativa efectiva para la detección de fraude en sistemas financieros, especialmente cuando se prioriza la minimización de fraudes no detectados.

7. Referencias

- [1] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001. doi: 10.1023/A:1010933404324.
- [2] A. Dal Pozzolo, G. Bontempi, M. Snoeck, and D. Pedreschi, “Adapting machine learning techniques to handle concept drift and class imbalance in fraud detection,” *IEEE Intelligent Systems*, vol. 30, no. 3, pp. 70–78, 2015. doi: 10.1109/MIS.2015.45.
- [3] N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, “SMOTE: Synthetic minority over-sampling technique,” *Journal of Artificial Intelligence Research*, vol. 16, pp. 321–357, 2002. Available: <https://www.jair.org/index.php/jair/article/view/10302>
- [4] V. Chandola, A. Banerjee, and V. Kumar, “Anomaly detection: A survey,” *ACM Computing Surveys*, vol. 41, no. 3, pp. 1–58, 2009. doi: 10.1145/1541880.1541882.
- [5] A. C. Bahnsen, D. Aouada, and B. Ottersten, “Example-dependent cost-sensitive decision trees,” *Expert Systems with Applications*, vol. 42, no. 19, pp. 6609–6619, 2015. doi: 10.1016/j.eswa.2015.04.042.