



# INSTITUTO POLITÉCNICO NACIONAL

---



## *ESCUELA SUPERIOR DE COMPUTACIÓN [ESCOM]*

*Lic. en Ciencias de Datos*

---

**Análisis de Series de Tiempo**

**Proyecto**

**“Predicción de Afluencia del Metro  
CDMX”**

---

Pacheco Molina Miguel Alejandro

Soria Martínez Jesús Armando

---

21/11/2025

## 2. Contexto de los datos y variable objetivo

### 2.1 Contexto del problema

El Metro de la Ciudad de México es uno de los sistemas de transporte más utilizados del mundo, movilizando millones de usuarios diariamente. La demanda del servicio presenta fluctuaciones derivadas de factores como días laborales, fines de semana, eventos especiales, fallas operativas, cierres de líneas o temporadas vacacionales.

Analizar y predecir la afluencia permite mejorar la planeación operativa, la asignación de recursos y la toma de decisiones en políticas de movilidad urbana.

### 2.2 Área de aplicación

Este análisis se ubica dentro del ámbito de la economía del transporte y planeación urbana, ya que la demanda del transporte masivo tiene efectos directos en:

- Movilidad de la población
- Productividad económica
- Distribución de horarios y trenes
- Identificación de anomalías y eventos atípicos

El estudio de series temporales permite modelar la dinámica de la demanda y anticipar comportamientos futuros.

### 2.3 Descripción del dataset

- Nombre: Afluencia diaria del Metro de la CDMX
- Fuente: Datos Abiertos de la Ciudad de México
- Periodo analizado: *1 de enero de 2021 – 1 de septiembre de 2025*
- Frecuencia temporal: Diaria
- Variables relevantes:
  - Fecha
  - Línea
  - Afluencia total (entradas registradas por día)
  - Tipo de pago

Para este análisis se trabajó exclusivamente con la afluencia total diaria del sistema, agregando todas las estaciones y líneas.

## 2.4 Variable objetivo

La variable objetivo es la *afluencia diaria*, definida como el número total de usuarios que ingresan al sistema Metro cada día.

Esta variable se modela como una serie temporal con el objetivo de:

- Identificar tendencias
- Detectar estacionalidad
- Encontrar anomalías
- Realizar pronósticos de afluencia futura

### Enlace al colab:

[https://colab.research.google.com/drive/1GvVXudmOQ0r2z2nB0AhGJzFRdlKCWy-Y?usp=sharing#scrollTo=TGj8kC3\\_-22H](https://colab.research.google.com/drive/1GvVXudmOQ0r2z2nB0AhGJzFRdlKCWy-Y?usp=sharing#scrollTo=TGj8kC3_-22H)

## 3. Análisis de la serie original

### 3.1 Preprocesamiento inicial

Para comenzar el análisis, se realizó un preprocesamiento básico de la serie con el objetivo de preparar los datos para su visualización y estudio.

Las acciones fueron:

- Conversión de la columna de fechas al tipo datetime.
- Tratamiento de la columna Línea debido a un problema de codificación.
- Ordenamiento temporal de los registros.
- Agregación de afluencia total por día.
- Revisión de valores faltantes y eliminación/preparación de registros incompletos.
- Ajuste del índice temporal para trabajar la serie como DatetimeIndex.

Este preprocesamiento permitió obtener la serie diaria completa de afluencia del Metro desde enero de 2021 hasta septiembre de 2025.


### 3.2 Visualización de la serie diaria

Se graficó la serie diaria completa.

El comportamiento se observa muy denso debido al alto número de observaciones (más de 1300 días), pero permite identificar tendencias generales y variabilidad diaria marcada.

Puntos observables:

- Patrones semanales visibles (picos entre semana, caídas los fines de semana).
- Tendencia creciente en ciertos periodos.
- Caídas abruptas posiblemente asociadas a eventos (cierres, fallas, días festivos).




**Figura 1:** *Afluencia diaria de la serie completa (Enero2021 – Julio2025)*

### 3.3 Visualización de la serie mensual

Para apreciar mejor el comportamiento global, se realizó una agregación mensual.

La serie mensual permitió observar:


- Tendencia más limpia y suave.
- Ciclos recurrentes en distintos meses del año.
- Posible estacionalidad anual.
- Variaciones fuertes en ciertos meses específicos.



**Figura 2:** *Afluencia mensual de la serie completa (Enero2021 – Julio2025)*

### 3.4 Descomposición de la serie temporal

Se aplicó una descomposición clásica aditiva (o multiplicativa, según lo que usaste) para identificar las tres componentes (tendencia, estacionalidad, residuos)



*Figura 3: Descomposición en (Tren, Seasonal, Resid) de la serie original*

Las gráficas permitieron observar:

- Una **tendencia global creciente** en grandes intervalos.
- Una **estacionalidad clara**, con patrones repetitivos por periodos.
- Residuos relativamente acotados pero con episodios de gran variabilidad.

Esta descomposición confirma que la serie presenta tanto estructura determinística como ruido aleatorio.

### 3.5 Prueba de estacionariedad (ADF)

Se aplicó la prueba ADF (Augmented Dickey-Fuller) a la serie original.

```
result_adf = adfuller(ts_diaria.dropna())

print("Resultados ADF para la Serie Completa (2021-2025)")
print(f"Estadístico ADF: {result_adf[0]:.4f}")
print(f"Valor p (p-value): {result_adf[1]:.4f}")

# Interpretación automática
if result_adf[1] < 0.05:
    print("La serie es estacionaria (se rechaza H0).")
else:
    print("La serie NO es estacionaria (no se rechaza H0).")


Resultados ADF para la Serie Completa (2021-2025)
Estadístico ADF: -3.5858
Valor p (p-value): 0.0060
La serie es estacionaria (se rechaza H0).
```

*Figura 4: Implementación de la prueba ADF*

El p-value fue mayor a 0.05, indicando que la serie **es estacionaria** en su forma original. Esto no se esperaba debido a la tendencia y estacionalidad observadas.

### 3.6 Gráficos ACF y PACF

Finalmente se analizaron las gráficas de autocorrelación (ACF) y autocorrelación parcial (PACF) de la serie original.



***Figura 5: Graficas ACF y PACF sobre la Serie Original***

Se observaron:

- En la ACF se observa un comportamiento de decaimiento extremadamente lento en la Función de Autocorrelación. Las correlaciones significativas se mantienen altas incluso después de 50 rezagos, esto indica tendenci fuerte, la media de la serie cambia significativamente a lo largo de los años.
- Estacionalidad Semanal Marcada: Tanto en la ACF como en la PACF, se observan picos prominentes y repetitivos cada 7 rezagos (7, 14, 21, 28...). Esto confirma la fuerte estacionalidad semanal del Metro.


## 4. Análisis de la Serie Segmentada (Selección 2023 – Frecuencia Semanal)

Con el fin de eliminar los efectos atípicos presentes en los primeros años de la serie principalmente derivados de la pandemia y de fluctuaciones extremas por cierres de líneas se decidió segmentar la serie original y trabajar únicamente con el año 2023, periodo que representa un comportamiento más estable y representativo de la operación normal del Metro de la CDMX.

Adicionalmente, la serie original en frecuencia diaria presenta variaciones muy marcadas entre días hábiles y fines de semana, lo que introduce un ruido considerable. Para suavizar estas fluctuaciones de alta frecuencia y facilitar la identificación de tendencias y patrones estacionales, los datos se transformaron a frecuencia semanal, sumando la afluencia total de cada semana del año.

### 4.1 Análisis Exploratorio de la Serie Semanal (2023)

Tras aplicar el filtrado temporal y la agregación semanal, se obtiene la serie Afluencia Semanal 2023, la cual presenta un comportamiento notablemente más suave que la serie diaria original.



**Figura 6:** Serie mensual en el intervalo 2023


El análisis visual revela:

- Una tendencia general ascendente en el primer trimestre.
- Caídas pronunciadas en periodos asociados a festivos y vacaciones (Semana Santa, diciembre).
- Menor ruido intra-semanal debido al proceso de agregación.



## 4.2 Evaluación de Estacionariedad a través de Medias y Varianzas Móviles

Se calcularon medias y varianzas móviles utilizando una ventana de 7 semanas, suficiente para suavizar el ruido de corto plazo pero sensible a cambios estructurales.



**Figura 7:** Media y Varianza Móviles.

Los resultados muestran:


- Media móvil: No constante; incrementos y descensos marcados, especialmente en los periodos vacacionales.
- Varianza móvil: Altamente inestable, con picos de volatilidad en el primer trimestre.

Este comportamiento indica que la serie semanal mantiene variaciones en sus niveles y dispersión.

## 4.3 Descomposición de Componentes

Se descompuso la serie en sus componentes fundamentales:

- Componente Observada: Serie semanal original.
- Tendencia: Confirma una dinámica no lineal con valles pronunciados y picos moderados.
- Estacionalidad: Con un periodo de 7 semanas, se identifican ciclos suaves asociados a la dinámica propia del transporte urbano.
- Residuo: Exhibe valores atípicos negativos en los mismos periodos donde la tendencia tiene caídas abruptas.




**Figura 8:** Descomposición en (Trend, Seasonal, Resid).

Esta descomposición sugiere que la serie semanal, aunque más limpia, aún presenta componentes estructurales relevantes.

#### 4.4 Análisis de Dependencia Temporal (ACF y PACF)

Se generaron las gráficas ACF y PACF para evaluar correlaciones temporales:



**Figura 9:** *Grafica ACF y PACF.*

- ACF: Excepto por el lag 0, ningún otro lag (1–7) es significativo. Esto indica la ausencia de dependencia entre semanas consecutivas.
- PACF: No muestra picos relevantes. Esto confirma la ausencia de estructura autoregresiva.

La serie semanal muestra un comportamiento cercano al ruido blanco.

#### 4.5 Prueba Ljung–Box

Se aplicó el test Ljung–Box para evaluar autocorrelación global.

```
ljung = acorr_ljungbox(series, lags=[10, 20, 30], return_df=True)
print("--- Ljung-Box Test ---")
print(ljung)
```

|    | lb_stat  | lb_pvalue |
|----|----------|-----------|
| 10 | 2.391945 | 0.992359  |
| 20 | 6.707494 | 0.997540  |
| 30 | 7.572724 | 0.999989  |

**Figura 10:** *Implementación de la Prueba Ljung-Box.*

- En todos los lags evaluados, no se rechaza  $H_0$ .
- Los p-values se mantienen altos, sin evidencia de autocorrelación.

La serie semanal puede considerarse estadísticamente independiente en el corto plazo, lo que coincide con los resultados del ACF y PACF.

## 4.6 Prueba de Raíz Unitaria (ADF)

Se aplicó la prueba ADF para evaluar estacionariedad formal.

```
adf_result = adfuller(series)
print("\n--- Augmented Dickey-Fuller Test ---")
print(f"ADF Statistic: {adf_result[0]:.4f}")
print(f"p-value: {adf_result[1]:.4f}")
for key, value in adf_result[4].items():
    print(f"Critical Value {key}: {value:.4f}")
print("Decisión:", "Estacionaria" if adf_result[1] < 0.05 else "No estacionaria")

--- Augmented Dickey-Fuller Test ---
ADF Statistic: -13.4131
p-value: 0.0000
Critical Value 1%: -3.5629
Critical Value 5%: -2.9190
Critical Value 10%: -2.5974
Decisión: Estacionaria
```

*Figura 11: Implementación de la Prueba ADF.*

- ADF Statistic =  $-13.4131$
- Valores críticos:
  - 1%:  $-3.5629$
  - 5%:  $-2.9190$
  - 10%:  $-2.5974$

Como el estadístico es menor que todos los valores críticos se rechaza  $H_0$  con alta confianza. La serie semanal es estacionaria, incluso sin aplicar diferenciación.

## 5. Justificación de la Serie Final Seleccionada


En el análisis anterior trabajamos con la serie del año 2023 agregada a frecuencia semanal, lo que permitió suavizar la variabilidad diaria y estudiar su comportamiento general. Sin embargo, dicha serie perdió completamente la estructura temporal necesaria para modelar, ya que:

- La estacionalidad semanal desapareció al sumar los datos.
- La serie resultante se comportó como ruido blanco (ACF, PACF y Ljung-Box sin autocorrelación significativa).
- Los patrones operativos importantes del Metro como variación entre días hábiles, fines de semana y días festivos ya no pueden capturarse a nivel semanal.

Por estas razones, la serie semanal fue útil únicamente para el análisis exploratorio, pero no es adecuada para construir modelos ARIMA/SARIMA.

Siguiendo la recomendación de la profesora y considerando lo anterior, se seleccionó como serie final la Serie con observación diaria del año 2023 la cual conserva:

- la estacionalidad natural de 7 días,
- la autocorrelación necesaria para modelado,
- la variabilidad diaria relevante para predicción operativa.



***Figura 12: Serie Final.***


## 6. Modelos Propuestos

En esta sección se describen los modelos desarrollados durante la práctica, incluyendo el análisis previo realizado para determinar las órdenes apropiadas, el modelo propuesto con base en la inspección visual de la ACF y PACF, y el modelo ajustado mediante búsqueda automática en un grid reducido. Finalmente, se presenta una comparación inicial entre ambos modelos.

### 6.1. Análisis previo para la selección de los modelos

Antes de ajustar un modelo SARIMA, se realizó un análisis exploratorio para identificar las características principales de la serie temporal correspondiente al año 2023:

Se realizó una descomposición de la serie.



*Figura 13: Descomposición de la Serie Final.*


Resultados:

- La descomposición mostró un **comportamiento estacional semanal** bien definido, donde la demanda aumenta consistentemente en ciertos días de la semana.
- La serie no presentó una tendencia clara durante el año.

### 6.3. Transformación de la Serie con Diferenciación Estacional

La prueba de raíz unitaria **ADF** indicó que no era necesario aplicar diferenciación regular, por lo que **d = 0**.

Para eliminar la estacionalidad semanal, se aplicó una diferencia estacional, estableciendo **D = 1** con un período **s = 7**.




**Figura 14:** Resultado de la Diferenciación Estacional de grado 7.

Al aplicar una diferenciación estacional con un rezago de 7 días se logró eliminar el fuerte patrón semanal de la serie, el eje vertical en el componente Seasonal se redujo drásticamente pasando de millones de usuarios a un rango de 20,000, esto nos dice que el ciclo semanal ha sido removido casi en su totalidad. Esto permite aislar y visualizar claramente los días atípicos y festivos, que ahora aparecen como picos pronunciados en la serie transformada y los residuos.

## 6.2. Modelo Propuesto Visualmente

Se analizó las funciones autocorrelación y a partir de los patrones identificados en la ACF y PACF, se planteó el siguiente modelo inicial.



*Figura 15: Graficas ACF y PACF de la Serie Transformada.*

### Modelo Propuesto:

$$\text{SARIMA}(1, 0, 1)(0, 1, 1)_7$$

### Justificación de los parámetros

- $p = 1$  y  $q = 1$ : la ACF y la PACF muestran picos significativos en el rezago 1, indicando la presencia de un componente AR simple y un componente MA simple.
- $d = 0$ : la serie ya es estacionaria en media sin necesidad de diferenciación regular.
- $P = 0$ : no se observó una estructura AR estacional definida en la PACF en múltiplos de 7.
- $Q = 1$ : la ACF presenta un pico significativo en el rezago estacional 7, justificando un componente MA estacional.
- $D = 1, s = 7$ : se usó una diferencia estacional semanal para eliminar la estacionalidad observable.

### Diagnóstico del modelo

- Los residuos se comportaron como **ruido blanco**, sin autocorrelaciones significativas en la mayoría de los rezagos.
- Sin embargo, los residuos mostraron **outliers asociados a días atípicos o festivos**, lo que afecta la normalidad.
- A pesar de estas anomalías, el modelo capturó adecuadamente el patrón semanal característico de la serie.



### 6.3. Búsqueda Automática (Grid Search Reducido)

Posteriormente, se realizó una búsqueda automática utilizando un **grid reducido** de combinaciones plausibles para  $p$ ,  $q$ ,  $P$  y  $Q$ , manteniendo  $d = 0$ ,  $D = 1$  y  $s = 7$ , tal como se trabajó en la sesión.

La búsqueda probó modelos en el rango:

- $p, q \in \{0, 1, 2\}$
- $P, Q \in \{0, 1\}$
- Manteniendo fija la estructura estacional

El modelo con mejor desempeño según el criterio AIC fue:

**Modelo encontrado:**

$$\text{SARIMA}(1, 0, 2)(0, 1, 1)_7$$

#### Justificación del mejor modelo

- La inclusión de  $q = 2$  permitió un mejor ajuste a las dependencias de corto plazo.
- El AIC disminuyó respecto al modelo inicial.
- Los residuos no mostraron autocorrelaciones significativas, indicando un mejor cumplimiento de los supuestos del modelo SARIMA.
- Persistieron problemas de normalidad por la presencia de valores atípicos vinculados a efectos de calendario, lo cual es esperable en este conjunto de datos.

### 6.4. Modelo SARIMA con variable exógena (SARIMAX)

Durante el análisis de los residuos del mejor modelo univariado encontrado mediante el Grid Search reducido (SARIMA(1,0,2)(0,1,1)<sub>7</sub>), se identificó **heterocedasticidad asociada a efectos de calendario**, principalmente en días festivos donde históricamente se observan caídas abruptas en la afluencia.

Para capturar esta variabilidad no explicada por la dinámica interna de la serie, se decidió incorporar una **variable exógena binaria**, construida de la siguiente manera:

- **0:** Día operativo normal
- **1:** Día festivo o de asueto (baja demanda esperada)

Los días festivos fueron definidos según las fechas oficiales de la **Ley Federal del Trabajo**, además de incluir otros días festivos.

## Reentrenando del modelo con exógena

Se reentrenó el mejor modelo identificado previamente:

$$\text{SARIMAX}(1, 0, 2)(0, 1, 1)_7 + \text{es\_festivo}$$

Se imprimieron los resultados completos del resumen (coeficientes AR, MA, términos estacionales,  $\sigma^2$ , AIC, etc.) y se observó lo siguiente:

- El **AIC disminuyó**, indicando una mejora sustancial en el ajuste global gracias a la incorporación del factor exógeno.
- El término **MA(2)** perdió significancia estadística ( $p = 0.456 > 0.05$ ), lo cual sugiere que la variable exógena absorbió variabilidad que antes intentaba explicar este componente.
- Dado que un parámetro no significativo puede inducir sobreparametrización, se decidió simplificar la estructura del modelo.

## Ajuste final con exógena

Se reentrenó un modelo más parsimonioso:

$$\text{SARIMAX}(1, 0, 1)(0, 1, 1)_7 + \text{es\_festivo}$$

Nuevamente se imprimieron los resultados del resumen y los diagnósticos de residuos:

- **Histograma + densidad:** residuos más centrados y con menor dispersión.
- **Correlograma:** confirma independencia (ruido blanco).
- **Q-Q Plot:** muestra alineación notablemente mejor respecto al modelo sin exógena, evidenciando que `es_festivo` captura la variabilidad de los días atípicos.

El modelo final resultó más estable, interpretable y estadísticamente significativo en todos sus parámetros.

## 7. Resultados de los Pronósticos

En esta sección se presentan los resultados obtenidos tras ajustar los modelos SARIMA seleccionados, evaluando su desempeño mediante análisis estadístico, diagnóstico de residuos y generación de pronósticos. Se incluyen también las métricas de precisión derivadas de validación cruzada.

### 7.1. Ajuste del Modelo SARIMA Propuesto Inicialmente

El primer modelo estimado fue el **SARIMA(1,0,1)(0,1,1)<sub>7</sub>**, seleccionado a partir del análisis visual de las gráficas ACF y PACF de la serie diferenciada estacionalmente ( $\text{lag} = 7$ ).

A continuación se presenta el resumen estadístico del modelo:

|                         | coef      | std err  | z        | P> z              | [0.025   | 0.975]   |
|-------------------------|-----------|----------|----------|-------------------|----------|----------|
| ar.L1                   | 0.8072    | 0.052    | 15.500   | 0.000             | 0.705    | 0.909    |
| ma.L1                   | -0.3389   | 0.073    | -4.638   | 0.000             | -0.482   | -0.196   |
| ma.S.L7                 | -0.6084   | 0.039    | -15.687  | 0.000             | -0.684   | -0.532   |
| sigma2                  | 1.213e+11 | 2.11e-13 | 5.74e+23 | 0.000             | 1.21e+11 | 1.21e+11 |
| =====                   |           |          |          |                   |          |          |
| Ljung-Box (L1) (Q):     |           |          | 0.57     | Jarque-Bera (JB): |          | 3063.77  |
| Prob(Q):                |           |          | 0.45     | Prob(JB):         |          | 0.00     |
| Heteroskedasticity (H): |           |          | 0.73     | Skew:             |          | -2.63    |
| Prob(H) (two-sided):    |           |          | 0.09     | Kurtosis:         |          | 16.53    |
| =====                   |           |          |          |                   |          |          |


*Figura 16: Resumen del modelo SARIMA (1,0,1)(0,1,1,7).*

- Los coeficientes AR(1) y MA(1) fueron estadísticamente significativos.
- El parámetro estacional MA(1) capturó adecuadamente la dependencia semanal.
- El AIC y BIC sugieren un ajuste razonable, aunque no óptimo.
- El término  $\sigma^2$  indica una varianza considerable en los residuos, coherente con la presencia de días festivos y atípicos.

### 7.2. Diagnóstico del Modelo Propuesto

Se evaluaron los residuos mediante gráficos y pruebas estadísticas:

- **Residuos alrededor de cero** → el modelo captura la dinámica principal.
- **Heterocedasticidad visible** → picos asociados a días festivos o eventos atípicos.
- **ACF/PACF de residuos:** la mayoría de los rezagos cae dentro de bandas de confianza.
- **Prueba de Ljung-Box:** se rechazó la hipótesis nula, indicando presencia de autocorrelación leve debido a clusters de errores en días festivos.



**Figura 17:** Diagnostico del Modelo.

### 7.3. Validación Cruzada del Modelo Inicial

Se aplicó validación cruzada con ventanas deslizantes para evaluar la capacidad predictiva del modelo:

```
Validación Cruzada para el Modelo Propuesto Visualmente
RMSE promedio: 318,283.15
MAE promedio: 183,243.18
MAPE promedio: 7.57%
```


**Figura 18:** Resultados de la Validación Cruzada del Modelo Inicial.

#### Interpretación:

- El modelo presenta un error relativo menor al 8%, lo que indica buena capacidad predictiva en días regulares.
- El RMSE es considerablemente mayor que el MAE debido a errores altos concentrados en días festivos.

## 7.4. Pronóstico del Modelo Inicial

Se generó un pronóstico a 10 días.



**Figura 19:** Pronostico a 10 pasos del Modelo Inicial y comparación con los datos reales.

### Interpretación:

- El modelo reproduce correctamente el ciclo semanal.
- Sin embargo, después de las caídas de fin de año, el modelo asume una recuperación inmediata, lo que ocasiona **sobreestimación** en los primeros días laborales de enero.

## 7.5. Ajuste del Mejor Modelo Encontrado por Búsqueda Automática

Mediante un algoritmo de búsqueda sencilla (grid search), se encontró que el modelo con mejor desempeño fue:

**SARIMA(1,0,2)(0,1,1)\_7**

Este modelo añadió un segundo término MA que redujo la dependencia serial residual y mejoró el ajuste general.


| SARIMAX Results         |                                 |          |                   |                   |           |          |
|-------------------------|---------------------------------|----------|-------------------|-------------------|-----------|----------|
| =====                   |                                 |          |                   |                   |           |          |
| Dep. Variable:          | afluencia                       |          |                   | No. Observations: | 365       |          |
| Model:                  | SARIMAX(1, 0, 2)x(0, 1, [1], 7) |          |                   | Log Likelihood    | -5016.962 |          |
| Date:                   | Fri, 21 Nov 2025                |          |                   | AIC               | 10043.924 |          |
| Time:                   | 23:55:39                        |          |                   | BIC               | 10063.326 |          |
| Sample:                 | 01-01-2023                      |          |                   | HQIC              | 10051.640 |          |
|                         | - 12-31-2023                    |          |                   |                   |           |          |
| Covariance Type:        | opg                             |          |                   |                   |           |          |
| =====                   |                                 |          |                   |                   |           |          |
|                         | coef                            | std err  | z                 | P> z              | [0.025    | 0.975]   |
| -----                   |                                 |          |                   |                   |           |          |
| ar.L1                   | 0.9922                          | 0.010    | 98.731            | 0.000             | 0.972     | 1.012    |
| ma.L1                   | -0.4706                         | 0.055    | -8.551            | 0.000             | -0.578    | -0.363   |
| ma.L2                   | -0.2713                         | 0.067    | -4.069            | 0.000             | -0.402    | -0.141   |
| ma.S.L7                 | -0.9329                         | 0.045    | -20.953           | 0.000             | -1.020    | -0.846   |
| sigma2                  | 1.22e+11                        | 2.75e-13 | 4.44e+23          | 0.000             | 1.22e+11  | 1.22e+11 |
| =====                   |                                 |          |                   |                   |           |          |
| Ljung-Box (L1) (Q):     | 0.06                            |          | Jarque-Bera (JB): | 3722.25           |           |          |
| Prob(Q):                | 0.81                            |          | Prob(JB):         | 0.00              |           |          |
| Heteroskedasticity (H): | 0.78                            |          | Skew:             | -2.90             |           |          |
| Prob(H) (two-sided):    | 0.17                            |          | Kurtosis:         | 17.69             |           |          |
| =====                   |                                 |          |                   |                   |           |          |

*Figura 20: Resumen del modelo SARIMA (1,0,2)(0,1,1,7).*

- El término MA(2) resultó significativo y mejoró la dinámica temporal.
- El AIC y BIC disminuyeron respecto al modelo inicial.
- Los residuos muestran independencia temporal (ruido blanco), aunque la normalidad aún no se cumple por efectos de días festivos.

## 7.6. Diagnóstico del Modelo Óptimo

- **Correlogramas de residuos:** no presentan autocorrelación significativa.
- **Prueba de Ljung-Box:** indica independencia temporal, mejorando respecto al primer modelo.
- **Q-Q plot:** muestra colas pesadas y asimetría, esperadas por outliers derivados de días festivos.



**Figura 21:** Diagnostico del Modelo.

## 7.6. Validación Cruzada del Modelo Seleccionado

**Tabla 7.6 — Validación Cruzada (Modelo Óptimo)**


```
Validando modelo ganador: SARIMA(1, 0, 2)x(0, 1, 1, 7)
RMSE promedio: 314,446.14
MAE promedio: 181,127.35
MAPE promedio: 7.54%
```

**Figura 22:** Resultados de la Validación Cruzada.

### Interpretación:

- Mejora ligera en todas las métricas respecto al modelo inicial.
- La diferencia es más notable en RMSE, indicando que el nuevo término MA reducirá errores grandes.

## 7.7. Pronóstico del Modelo Óptimo



**Figura 23:** Pronostico a 10 pasos del Mejor Modelo y comparación con los datos Reales.

- El modelo captura adecuadamente la estacionalidad semanal.
- Predice mejor las variaciones regulares, aunque aún no corrige eventos atípicos por falta de variables exógenas.
- Es razonablemente estable y adecuado para pronósticos de corto plazo.

## 7.8. Inclusión de Variable Exógena (SARIMAX)

A pesar de que el modelo SARIMA óptimo capturó adecuadamente la estacionalidad semanal, los residuales aún mostraban heterocedasticidad y errores elevados en días festivos.

Como se identificó en los diagnósticos previos, el problema no era de estructura temporal sino de eventos de calendario no incluidos en el modelo.

### Creación de la variable exógena



Se construyó una variable binaria denominada **es\_festivo**, definida como:

- **0 → Día operativo normal**
- **1 → Día festivo o de asueto**

Las fechas seleccionadas corresponden a festivos oficiales según la **Ley Federal del Trabajo**, además de:

- Jueves Santo
- Viernes Santo
- Día de Muertos

Estas fechas históricamente presentan caídas drásticas en la afluencia y son responsables de los picos de error observados en los modelos univariados.

### **7.9. Reentrenamiento del Modelo con Variable Exógena**

El primer experimento consistió en reentrenar el mejor modelo previo:

$$\text{SARIMAX}(1,0,2)(0,1,1)_7 + \text{es\_festivo}$$

Tras ajustar el modelo con la variable exógena:

- El AIC disminuyó respecto al modelo univariado.
- El coeficiente asociado a la variable **es\_festivo** fue altamente significativo.
- El término MA(2) dejó de ser significativo  $\rightarrow p > 0.05$   
Esto indicó que la exógena absorbió la variabilidad que antes intentaba capturar MA(2).

Por ello, se decidió simplificar el modelo, manteniendo únicamente los componentes realmente necesarios.

### **7.10. Modelo Final SARIMAX Seleccionado**

El modelo resultante fue:

$$\text{SARIMAX}(1,0,1)(0,1,1)_7 + \text{es\_festivo}$$


Este modelo presenta:

| SARIMAX Results         |                               |                   |                   |       |           |          |
|-------------------------|-------------------------------|-------------------|-------------------|-------|-----------|----------|
| =====                   |                               |                   |                   |       |           |          |
| Dep. Variable:          | afluencia                     |                   | No. Observations: |       | 365       |          |
| Model:                  | SARIMAX(1, 0, 1)x(0, 1, 1, 7) |                   | Log Likelihood    |       | -4706.224 |          |
| Date:                   | Sat, 22 Nov 2025              |                   | AIC               |       | 9422.447  |          |
| Time:                   | 00:33:51                      |                   | BIC               |       | 9441.723  |          |
| Sample:                 | 01-01-2023                    |                   | HQIC              |       | 9430.121  |          |
|                         | - 12-31-2023                  |                   |                   |       |           |          |
| Covariance Type:        | opg                           |                   |                   |       |           |          |
| =====                   |                               |                   |                   |       |           |          |
|                         | coef                          | std err           | z                 | P> z  | [0.025    | 0.975]   |
| -----                   |                               |                   |                   |       |           |          |
| es_festivo              | -1.344e+06                    | 2.27e+04          | -59.067           | 0.000 | -1.39e+06 | -1.3e+06 |
| ar.L1                   | 0.8744                        | 0.037             | 23.321            | 0.000 | 0.801     | 0.948    |
| ma.L1                   | -0.5055                       | 0.060             | -8.477            | 0.000 | -0.622    | -0.389   |
| ma.S.L7                 | -0.4123                       | 0.023             | -18.173           | 0.000 | -0.457    | -0.368   |
| sigma2                  | 3.689e+10                     | 0.178             | 2.08e+11          | 0.000 | 3.69e+10  | 3.69e+10 |
| =====                   |                               |                   |                   |       |           |          |
| Ljung-Box (L1) (Q):     | 0.03                          | Jarque-Bera (JB): | 1250.39           |       |           |          |
| Prob(Q):                | 0.87                          | Prob(JB):         | 0.00              |       |           |          |
| Heteroskedasticity (H): | 0.62                          | Skew:             | -0.26             |       |           |          |
| Prob(H) (two-sided):    | 0.01                          | Kurtosis:         | 12.26             |       |           |          |
| =====                   |                               |                   |                   |       |           |          |

**Figura 24:** Resultados del Modelo Final SARIMAX.

- Todos los coeficientes estadísticamente significativos
- AIC más bajo que cualquiera de los modelos anteriores
- Residuos más limpios, con menor varianza

## Diagnóstico de residuos



*Figura 25: Diagnostico de Residuos.*

- Correlogramas: sin autocorrelaciones significativas, se comportan como ruido blanco
- Q-Q plot: notable alineación con la distribución normal
- Reducción clara de los outliers que antes coincidían con días festivos

### 7.11. Validación Cruzada del Modelo con Exógena

Se aplicó nuevamente validación cruzada con ventanas deslizantes:

- **RMSE promedio:** 282,017.20
- **MAE promedio:** 210,111.36
- **MAPE promedio:** 7.82 %

#### Interpretación

- El **RMSE disminuyó fuertemente** (más de 30,000 pasajeros), lo que confirma que el modelo ahora gestiona mejor los días atípicos.
- Aunque el **MAPE aumentó ligeramente** (7.54% → 7.82%), este cambio es marginal frente al beneficio en estabilidad.
- El modelo se vuelve **más robusto**, especialmente para fechas complejas donde los modelos SARIMA fallaban.

### 7.12. Pronóstico del Modelo Final SARIMAX

Se generó un pronóstico a 10 pasos incorporando también la variable exógena prevista para los días futuros.



**Figura 26:** Pronostico a 5 pasos y comparación con los datos Reales.

- El patrón semanal se replica de forma adecuada.
- Las caídas por días festivos se reflejan de manera realista.
- No aparecen sobreestimaciones bruscas tras fechas atípicas.
- La serie pronosticada es más estable y ajustada a la dinámica real del sistema de transporte.

## 8. Comparación Final de Modelos

En esta sección se presenta la comparación cuantitativa entre los dos modelos SARIMA ajustados:

- **Modelo Propuesto Inicialmente:** SARIMA(1,0,1)(0,1,1)<sub>7</sub>
- **Modelo Seleccionado por Búsqueda Automática:** SARIMA(1,0,2)(0,1,1)<sub>7</sub>

La evaluación se realizó utilizando las métricas derivadas de la validación cruzada: **RMSE**, **MAE** y **MAPE**, que permiten medir y comparar la precisión predictiva entre modelos.

### 8.1. Tabla Comparativa de Errores (RMSE, MAE y MAPE)

| === TABLA COMPARATIVA FINAL DE MODELOS === |                                |                              |         |         |       |
|--------------------------------------------|--------------------------------|------------------------------|---------|---------|-------|
|                                            | Modelo                         | Parámetros                   | RMSE    | MAE     | MAPE  |
| 0                                          | Propuesta Visual               | (1, 0, 1) x (0, 1, 1, 7)     | 318,283 | 183,243 | 7.57% |
| 1                                          | Mejor Modelo (Busqueda Simple) | (1, 0, 1) x (0, 1, 1, 7)     | 314,446 | 181,127 | 7.54% |
| 2                                          | SARIMAX Final (+Exog)          | (1,0,1)x(0,1,1,7) + Festivos | 282,017 | 210,111 | 7.82% |

*Figura 27: Desempeño de los Modelos SARIMA.*

### 8.2. Interpretación de Resultados

Aunque el MAPE presentó un incremento marginal (7.82% frente a 7.54%), esta diferencia es relativamente pequeña y no afecta de manera sustancial la interpretación global del desempeño.

En contraste, el RMSE mostró una reducción considerable, pasando de aproximadamente 314 000 a 282 000. Esta mejora es especialmente relevante porque el RMSE penaliza con mayor peso los errores grandes, los cuales eran más frecuentes en los días festivos. Por ello, la disminución del RMSE sugiere que la inclusión de la variable exógena permitió al modelo capturar mejor los cambios abruptos asociados a estos eventos atípicos.

En consecuencia, aun cuando el MAPE aumentó ligeramente, la reducción significativa en el RMSE evidencia que el modelo con variable exógena ofrece un mejor desempeño en los escenarios donde los errores solían ser más severos, fortaleciendo la robustez general del pronóstico.

### 8.3. Posibles Mejoras y Trabajo Futuro

A pesar de que la inclusión de la variable exógena binaria redujo significativamente el RMSE, se identifican las siguientes áreas de oportunidad para perfeccionar la capacidad predictiva del modelo:

- Incorporación de periodos vacacionales (Calendario SEP y Universidades): Actualmente, el modelo penaliza días festivos puntuales, pero no contempla explícitamente los periodos vacacionales largos (Semana Santa completa, vacaciones de verano y receso invernal). Durante estos lapsos, la afluencia disminuy y no solo como un pico abrupto de un día. Agregar una variable exógena adicional para periodo vacacional ayudaría a modelar mejor estas semanas de baja demanda sostenida.
- Factores externos adicionales: Se podría evaluar la inclusión de variables climáticas (precipitación pluvial) o eventos masivos en la ciudad (conciertos, eventos deportivos), los cuales generan anomalías en la afluencia que no dependen estrictamente del calendario laboral.